

FACULDADE DE
CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE D
COIMBRA

Inteligência Artificial Probabilistica - Projeto Final

Trabalho Elaborado por:

Duarte Borges (Nº 2023181577)

João Raposeiro (Nº 2022215669)

Contents

1. Introdução 1
2. Dataset e preparação dos dados 1
3. Redes Bayesianas 3
    3.1 Estrutura manual da Rede Bayesiana 4
    3.2 Aprendizagem automática da estrutura 4
    3.3 Análise por D-separação 5
    3.4 Aprendizagem dos parâmetros: MLE e estimação Bayesiana 6
    3.5 Inferências probabilísticas 7
4. Classificação probabilística e quantificação de incerteza 8
    4.1 Modelo Naive Bayes 8
    4.2 Métricas de avaliação probabilística 9
    4.3 Calibração e Reliability Diagram 10
    4.4 Conformal Prediction 11
    4.5 Otimização Bayesiana dos hiperparâmetros 13
    4.6 Síntese da Parte 2 14
5. Teoria de utilidade e tomada de decisão 14
    5.1 Conversão das odds em probabilidades implícitas 14
    5.2 Valor esperado das apostas 15
    5.3 Estratégias avaliadas 15
    5.4 Resultados das estratégias 16
    5.5 Efeito do limiar de rejeição 18
    5.6 Análise crítica da utilidade 18
6. Discussão crítica 19
7. Conclusão 20

1. Introdução

A previsão de resultados de jogos de futebol é um problema naturalmente incerto, uma vez que o resultado de uma partida depende de fatores observáveis e não observáveis, como forma recente, contexto casa/fora, qualidade das equipas, histórico de confrontos diretos e eventos aleatórios durante o jogo. Este trabalho, tem o objetivo de desenvolver e avaliar modelos probabilísticos para jogos da liga portuguesa, considerando três resultados possíveis: vitória da equipa da casa (H), empate (D) e vitória da equipa visitante (A). Em vez de prever apenas a classe mais provável, pretende-se estimar uma distribuição de probabilidades sobre estes três resultados.

O projeto enquadra-se n unidade curricular de Inteligência Artificial Probabilística: Redes Bayesianas, classificação probabilística, quantificação de incerteza, calibração e tomada de decisão sob incerteza. Na primeira parte, são construídas e analisadas Redes Bayesianas com variáveis discretizadas relacionadas com forma recente, ataque, confrontos diretos e odds. Na segunda parte, é treinado e avaliado um classificador probabilístico Naive Bayes, usando métricas como Accuracy, Log Loss, Brier Score, Reliability Diagrams e Conformal Prediction. Na terceira parte, as probabilidades previstas são comparadas com as odds para avaliar estratégias de decisão baseadas em valor esperado, Reject Option e deferência para o mercado.

O foco principal é analisar a qualidade das probabilidades previstas, a sua calibração e a sua utilidade prática num contexto de decisão. Esta distinção é importante porque, como discutido nos slides de utilidade, probabilidades razoáveis não garantem automaticamente boas decisões: é necessário avaliar a ação tomada e a utilidade associada.

2. Dataset e preparação dos dados

O conjunto de dados utilizado tem informação histórica sobre jogos da liga portuguesa de futebol. Cada observação corresponde a um jogo, incluindo a data, a equipa da casa, a equipa visitante, os golos marcados por cada equipa, o resultado final e as odds associadas aos três resultados possíveis: vitória da equipa da casa (H), empate (D) e vitória da equipa visitante (A). No processo de carregamento e limpeza, as colunas originais foram renomeadas para nomes mais simples, como date, ht, at, hg, ag, result, h_odds, d_odds e a_odds, tendo sido também normalizados alguns nomes de equipas para evitar inconsistências.

Após o processamento, o dataset final utilizado neste trabalho contém **5583 jogos** e **31 variáveis**, cobrindo o período entre **06/01/2006** e **26/01/2026**. A variável alvo é result, com três classes possíveis. A distribuição das classes mostra que a vitória da equipa da casa é o resultado mais frequente, com **2466 jogos** aproximadamente **44.2%**, seguida da vitória da equipa visitante, com

1712 jogos aproximadamente **30.7%**, e do empate, com **1405 jogos** aproximadamente **25.2%**. Esta distribuição é importante porque mostra que o problema é desbalanceado: uma baseline simples que previsse sempre vitória da equipa da casa já teria uma accuracy relativamente elevada e por isso a avaliação dos modelos não deve depender apenas da accuracy.

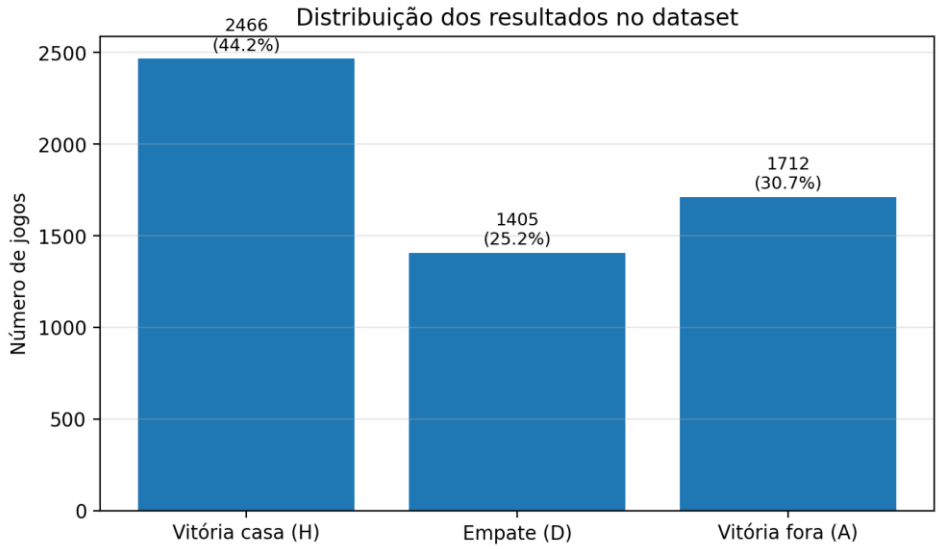


Figura 1 — Distribuição das classes H/D/A no dataset processado. A vitória da equipa da casa é a classe mais frequente.

Para enriquecer cada observação, foram criadas variáveis baseadas apenas em jogos anteriores, evitando fuga de informação temporal. Estas variáveis incluem forma recente das equipas, golos marcados e sofridos nos últimos jogos, desempenho casa/fora e histórico de confrontos diretos. Esta escolha é importante porque, num cenário real, um modelo só deve usar informação disponível antes do jogo que pretende prever.
Como a construção das Redes Bayesianas exige variáveis discretas, algumas variáveis numéricas foram convertidas em categorias. A forma recente foi discretizada em classes como poor, below avg, average, good e excellent. A força ofensiva foi discretizada em weak, average, above avg e strong. Foram ainda criadas variáveis categóricas compostas, como joint_attack, h2h_dominance e odds_favorite. A variável joint_attack combina a força ofensiva das duas equipas, h2h_dominance resume o histórico de confrontos diretos e odds_favorite identifica o favorito segundo as odds.

A tabela seguinte resume os principais grupos de variáveis usados no projeto:

Grupo	**Variáveis**
Identificação do jogo	date, ht, at
Resultado observado	hg, ag, result

Odds	h_odds, d_odds, a_odds
Forma recente	ht_form_points, at_form_points, ht_form, at_form
Ataque recente	ht_form_goals_scored, at_form_goals_scored, ht_attack, at_attack, joint_attack
Confronto direto	h2h_home_wins, h2h_draws, h2h_away_wins, h2h_dominance
Mercado de odds	odds_favorite

A divisão dos dados foi feita de forma temporal, em vez de aleatória. Esta decisão evita que informação de jogos futuros influencie a aprendizagem do modelo e aproxima a avaliação do cenário real de previsão. Assim, o dataset processado serve de base às três componentes do trabalho: Redes Bayesianas, classificação probabilística e avaliação de decisões com base nas odds.

3. Redes Bayesianas

A primeira componente experimental do trabalho consistiu na construção e análise de Redes Bayesianas para o domínio dos resultados de futebol. Esta escolha é adequada ao problema porque uma Rede Bayesiana permite representar uma distribuição conjunta de forma compacta através de um grafo acíclico dirigido e de distribuições condicionais locais. Nos slides da disciplina, as Redes Bayesianas são apresentadas precisamente como uma forma de evitar a especificação direta de uma tabela conjunta completa, usando nós para representar variáveis aleatórias, arestas para representar dependências diretas e a estrutura do grafo para codificar independências condicionais.

Neste trabalho, a Rede Bayesiana foi construída a partir de variáveis discretizadas do dataset, uma vez que estas são mais adequadas à estimação de tabelas de probabilidade condicionais. Foram utilizadas as seguintes variáveis:

Variável	**Significado**
ht_form	Forma recente da equipa da casa
at_form	Forma recente da equipa visitante
joint_attack	Combinação da força ofensiva recente das duas equipas
h2h_dominance	Domínio histórico nos confrontos diretos
odds_favorite	Favorito implícito nas odds
result	Resultado final do jogo: H, D ou A

Estas variáveis foram escolhidas por serem interpretáveis e por representarem fatores relevantes para o resultado de uma partida. A variável joint_attack combina as categorias ofensivas da equipa da casa e da equipa visitante, enquanto h2h_dominance resume o histórico dos

confrontos diretos e odds_favorite introduz informação do mercado de apostas. A discretização destas variáveis foi feita no processo de preparação dos dados, onde a forma recente foi transformada em categorias como poor, below avg, average, good e excellent, a força ofensiva em categorias como weak, average, above avg e strong, e as odds foram convertidas numa indicação categórica do favorito.

3.1 Estrutura manual da Rede Bayesiana

A primeira abordagem seguida foi uma estrutura manual baseada em conhecimento do domínio. Nesta estrutura, assumiu-se que o resultado do jogo depende diretamente da forma recente das duas equipas, da força ofensiva conjunta, do histórico de confrontos diretos e da informação presente nas odds. Assim, a estrutura definida foi:

Pai	**Filho**
ht_form	result
at_form	result
joint_attack	result
h2h_dominance	result
odds_favorite	result

Esta estrutura corresponde a uma modelação em que result é a variável central a explicar, recebendo como pais os principais fatores de contexto do jogo. A opção é interpretável: uma equipa da casa em boa forma, uma equipa visitante em má forma, um ataque conjunto desequilibrado ou um claro favorito nas odds deverão influenciar a distribuição de probabilidade sobre H, D e A.

A estrutura manual pode ser vista como uma aplicação da abordagem de *Knowledge Engineering*, discutida nos slides de aprendizagem de modelos gráficos. Nessa abordagem, o investigador escolhe as variáveis e a estrutura com base em conhecimento do domínio, testando depois se as respostas a queries típicas são plausíveis.

3.2 Aprendizagem automática da estrutura

Para comparar a estrutura manual com uma abordagem orientada pelos dados, foi também aplicada aprendizagem automática de estrutura através de Hill-Climb Search com score BIC. A estrutura aprendida automaticamente devolveu as seguintes arestas:

Pai	**Filho**
at_form	joint_attack
joint_attack	ht_form
h2h_dominance	odds_favorite
h2h_dominance	result
odds_favorite	at_form
odds_favorite	result

A comparação entre as duas estruturas mostra que existem duas arestas em comum: h2h_dominance → result e odds_favorite → result. Isto sugere que, tanto pela modelação manual como pelo critério estatístico usado na aprendizagem automática, o histórico de confrontos diretos e o favorito implícito nas odds aparecem como variáveis diretamente associadas ao resultado.

Por outro lado, a rede automática não ligou diretamente ht_form, at_form e joint_attack a result, ao contrário da estrutura manual. Em vez disso, criou relações intermédias entre variáveis explicativas, como at_form → joint_attack e joint_attack → ht_form. Esta diferença deve ser interpretada com cuidado: a orientação das arestas aprendidas automaticamente não deve ser lida necessariamente como causalidade. O algoritmo procura uma estrutura que melhore o score estatístico, não uma explicação causal do domínio. Nos slides, a aprendizagem de estrutura é descrita como o problema de estimar o grafo a partir dos dados, isto é, determinar como as variáveis dependem umas das outras; esta tarefa é distinta da aprendizagem de parâmetros quando a estrutura já é conhecida.

A estrutura aprendida automaticamente é útil como comparação, mas a estrutura manual mantém maior interpretabilidade para o domínio do futebol. Por isso, nas inferências principais foi privilegiada a rede manual com parâmetros estimados a partir dos dados.

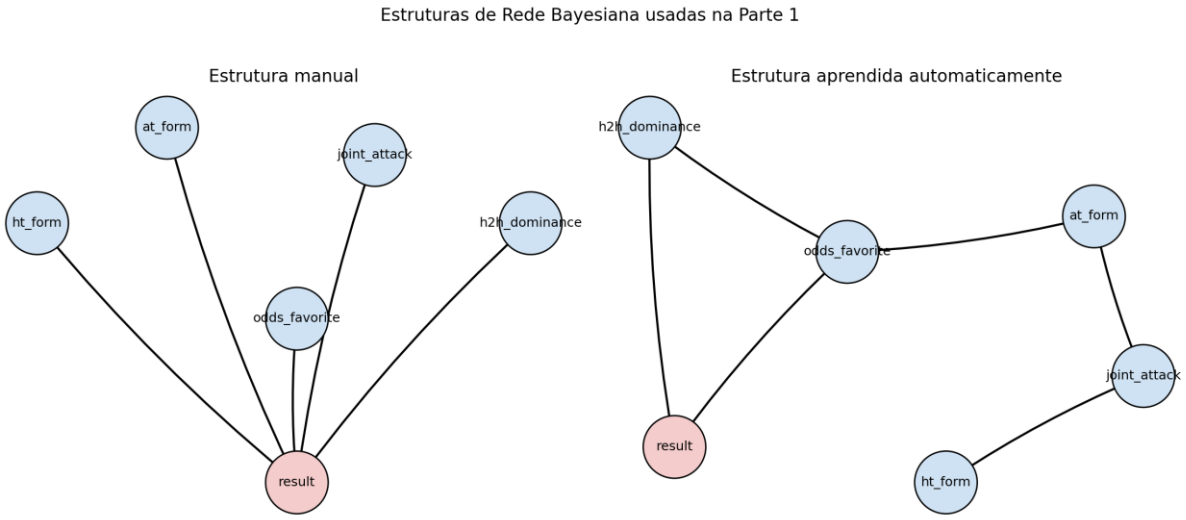


Figura 2 — Estruturas de Rede Bayesiana: estrutura manual baseada em conhecimento do domínio e estrutura aprendida automaticamente.

3.3 Análise por D-separação

Após definir a estrutura manual, foi realizada uma análise de D-separação para identificar independências condicionais induzidas pelo grafo. A D-separação é relevante porque permite compreender que hipóteses de independência estão a ser assumidas ao escolher uma determinada estrutura. Nos slides, é referido que duas variáveis são condicionalmente

independentes dado um conjunto observado se não existir caminho ativo entre elas; também é destacado que condicionar num collider, ou num dos seus descendentes, pode abrir um caminho que estava bloqueado.

Na estrutura manual, as variáveis explicativas são pais comuns de result. Assim, surgem estruturas do tipo:

$$ht_form \rightarrow result \leftarrow at_form$$

Esta configuração é um collider em result. Sem observar o resultado, ht_form e at_form ficam d-separadas na estrutura manual. No entanto, quando se condiciona em result, o collider é aberto e passa a existir dependência entre estas variáveis. Isto corresponde ao fenómeno de *explaining away*: sabendo que ocorreu um determinado resultado, a informação sobre uma causa possível pode alterar a interpretação sobre outra causa possível.

A análise efetuada confirmou este comportamento:

Variáveis	**Condicionamento**	**D-connected**
ht_form, at_form	nenhum	False
ht_form, at_form	result	True
ht_form, odds_favorite	nenhum	False
joint_attack, h2h_dominance	nenhum	False
joint_attack, h2h_dominance	result	True

Estes resultados mostram que, na rede manual, as variáveis explicativas são assumidas como independentes entre si antes de se observar o resultado, mas tornam-se dependentes quando o resultado é conhecido. Esta é uma consequência direta da estrutura em que várias causas apontam para a mesma variável efeito.

3.4 Aprendizagem dos parâmetros: MLE e estimação Bayesiana

Depois de definida a estrutura, foram estimados os parâmetros da Rede Bayesiana, isto é, as tabelas de probabilidade condicionais. Foram comparadas duas abordagens: Maximum Likelihood Estimation e estimação Bayesiana.

Na estimação por MLE, as probabilidades são obtidas a partir das frequências relativas observadas nos dados. Esta abordagem é simples e diretamente interpretável, mas pode sofrer em combinações raras de estados, especialmente quando o número de pais de uma variável é elevado. Os slides indicam que o MLE consiste em usar frequências relativas, mas também alertam para o risco de overfitting quando existem poucas observações para determinados casos.

A estimação Bayesiana, por sua vez, introduz uma prior sobre os parâmetros, suavizando as probabilidades estimadas. No contexto deste trabalho, isto é importante porque algumas combinações de ht_form, at_form, joint_attack, h2h_dominance e odds_favorite podem ser pouco frequentes. Sem suavização, o MLE pode atribuir probabilidades extremas ou pouco robustas a esses casos. A estimação Bayesiana permite incorporar pseudo-contagens através de uma prior, reduzindo o impacto de combinações raras e tornando as CPTs mais estáveis.

Ambos os modelos estimados foram validados com sucesso, ou seja, as CPDs obtidas eram compatíveis com a estrutura da rede. Na prática, as diferenças entre MLE e estimação Bayesiana tornam-se mais relevantes nos cenários com menor suporte empírico, onde a suavização impede que a rede atribua probabilidades demasiado extremas com base em poucos exemplos.

3.5 Inferências probabilísticas

Por fim, a Rede Bayesiana foi utilizada para realizar inferências probabilísticas sobre o resultado dos jogos. A inferência foi feita através de eliminação de variáveis, uma técnica em que se combinam fatores e se marginalizam variáveis não observadas para obter distribuições condicionais sobre as variáveis de interesse. Nos slides, a inferência por eliminação de variáveis é apresentada como uma sequência de operações de produto de fatores e marginalização, permitindo responder a queries do tipo $P(query \mid evidence)$.

Foram realizadas quatro queries principais usando a rede manual com estimação Bayesiana:

Query	**Evidência**	$P(A)$	$P(D)$	$P(H)$	**Resultado mais provável**
Q1	ht_form=good, odds_favorite=home	0.223	0.281	0.495	H
Q2	ht_form=average, at_form=average	0.341	0.302	0.357	H
Q3	h2h_dominance=home_dominant	0.255	0.272	0.473	H
Q4	ht_form=good, at_form=below avg, joint_attack=strong x weak, odds_favorite=home	0.381	0.406	0.213	D

A tabela mostra que a rede produz distribuições coerentes com a evidência observada. Quando a equipa da casa está em boa forma e é favorita nas odds, a vitória da casa torna-se o resultado mais provável, com P(H)=0.495. Quando ambas as equipas apresentam forma média, a distribuição fica mais equilibrada, indicando maior incerteza. O domínio histórico da equipa da casa também aumenta a probabilidade de H, com P(H)=0.473. A quarta query é a mais interessante criticamente: apesar de conter sinais aparentemente favoráveis à equipa da casa, a rede atribui maior probabilidade ao empate, com P(D)=0.406. Isto mostra que a inferência depende da interação entre as variáveis, da estrutura escolhida e do suporte empírico das combinações observadas nos dados.

De forma geral, a Parte 1 permitiu construir uma representação probabilística interpretável do domínio, comparar uma estrutura manual com uma estrutura aprendida automaticamente, analisar independências condicionais por D-separação, estimar CPTs por MLE e estimação Bayesiana, e realizar inferências sobre cenários concretos de jogo.

4. Classificação probabilística e quantificação de incerteza

A segunda parte do trabalho teve como objetivo treinar e avaliar classificadores probabilísticos para prever o resultado dos jogos. Ao contrário de um classificador que apenas devolve uma classe final, um classificador probabilístico devolve uma distribuição de probabilidade sobre as classes possíveis. Neste caso, para cada jogo, o modelo estima:

$$P(result = A \mid x), P(result = D \mid x), P(result = H \mid x)$$

Esta abordagem está alinhada com os slides de quantificação de incerteza, onde é referido que, em classificação probabilística, o objetivo não é apenas devolver $\hat{y} = \arg\max_k P(Y = k \mid X)$, mas sim produzir o vetor completo de probabilidades por classe. Esse vetor fornece uma medida natural da confiança do modelo: previsões como $[0.01, 0.02, 0.97]$representam elevada confiança, enquanto previsões como $[0.31, 0.35, 0.34]$indicam maior incerteza.

4.1 Modelo Naive Bayes

O principal modelo utilizado nesta parte foi o Naive Bayes, uma vez que este é explicitamente pedido no enunciado do projeto. O Naive Bayes é um classificador probabilístico baseado na regra de Bayes. Dadas as features $X_1, X_2, \ldots, X_n$e uma classe Y, o modelo estima a probabilidade posterior de cada classe e escolhe a classe com maior probabilidade. Nos slides da disciplina, o problema de classificação Bayesiana é apresentado precisamente como a tarefa de prever uma label categórica Ya partir de um conjunto de features, usando um classificador probabilístico baseado na regra de Bayes.

A principal simplificação do Naive Bayes é assumir que as features são condicionalmente independentes dada a classe. Assim, em vez de modelar diretamente a distribuição conjunta completa $P(X_1, \ldots, X_n \mid Y)$, o modelo aproxima essa distribuição como o produto das probabilidades condicionais individuais:

$$P(X_1, \ldots, X_n \mid Y) \approx \prod_i P(X_i \mid Y)$$

Esta hipótese reduz drasticamente o número de parâmetros necessários, tornando o modelo simples e eficiente. No entanto, é também uma limitação importante, porque no domínio do futebol várias features não são verdadeiramente independentes. Por exemplo, ht_form, ht_attack

e odds_favorite podem estar relacionadas entre si. Os slides também indicam que, embora o Naive Bayes devolva probabilidades úteis para medir confiança, a hipótese de independência pode levar a probabilidades mal calibradas.

No trabalho, o modelo foi treinado usando variáveis categóricas/discretizadas, incluindo forma recente, ataque recente, ataque conjunto e domínio histórico. Foi usada codificação one-hot para transformar estas variáveis categóricas numa representação adequada ao classificador. A avaliação foi feita no conjunto de teste definido temporalmente, garantindo que o modelo é avaliado em jogos posteriores aos usados no treino e calibração.

4.2 Métricas de avaliação probabilística

A avaliação do modelo não se limitou à accuracy. Embora a accuracy indique a proporção de jogos em que a classe mais provável corresponde ao resultado real, ela ignora a qualidade das probabilidades. Por exemplo, prever H com 0.95 de probabilidade e errar é muito mais grave, do ponto de vista probabilístico, do que prever H com 0.36 e errar. Por isso, foram também utilizadas métricas próprias para avaliação de distribuições probabilísticas: Log Loss e Brier Score.

Os slides de quantificação de incerteza apresentam Log Loss e Brier Score como *proper scoring rules* para classificação probabilística. O Brier Score mede a distância quadrática entre as probabilidades previstas e a codificação one-hot da classe real, avaliando simultaneamente calibração e sharpness. O Log Loss, ou cross-entropy, penaliza fortemente previsões confiantes mas erradas. O Expected Calibration Error, por sua vez, mede especificamente a diferença entre a confiança média prevista e a accuracy observada em grupos de previsões.

Os principais resultados obtidos foram:

Modelo	**Accuracy**	**Log Loss**	**Brier Score**
Naive Bayes, $\alpha = 1$	0.529991	1.109198	0.617724
Naive Bayes com Bayesian Optimization	0.529991	1.073991	0.609319

Os resultados mostram que a otimização Bayesiana do hiperparâmetro αmelhorou o Log Loss e o Brier Score, mas não alterou a accuracy. Esta diferença é relevante: a classe prevista pelo modelo pode permanecer igual, mas as probabilidades atribuídas a cada classe podem tornar-se mais adequadas. Assim, a otimização melhorou a qualidade probabilística das previsões, ainda que não tenha aumentado a proporção de classes corretamente previstas.

A interpretação do Log Loss também deve ser feita com cuidado. Como existem três classes, uma previsão uniforme $P(A) = P(D) = P(H) = 1/3$teria Log Loss aproximadamente igual a:

$$-\log(1/3) = \log(3) \approx 1.099$$

Assim, o modelo Naive Bayes com $\alpha = 1$, com Log Loss de 1.109, fica ligeiramente pior do que uma previsão uniforme em termos de Log Loss. Já o modelo otimizado, com Log Loss de 1.074, fica ligeiramente melhor. Isto sugere que o modelo aprende algum sinal útil, mas que as suas probabilidades ainda são pouco fortes quando comparadas com uma baseline uniforme.

O mesmo raciocínio aplica-se ao Brier Score. Para três classes, uma previsão uniforme tem Brier Score aproximadamente igual a 0.667. Os valores obtidos, 0.618 e 0.609, são melhores do que essa baseline, indicando que as probabilidades do modelo contêm alguma informação relevante. No entanto, a proximidade a esta baseline simples mostra que o problema é difícil e que as features utilizadas não são suficientes para produzir probabilidades altamente informativas.

4.3 Calibração e Reliability Diagram

Para avaliar se as probabilidades previstas pelo modelo correspondem às frequências observadas, foi construído um Reliability Diagram. A calibração é uma propriedade diferente da accuracy: um modelo pode acertar muitas vezes e estar mal calibrado, ou acertar menos mas produzir probabilidades mais honestas. Nos slides, um modelo calibrado é definido como um modelo cujas probabilidades previstas correspondem às frequências observadas; por exemplo, entre os casos em que o modelo prevê probabilidade 0.8, cerca de 80% deveriam ser efetivamente positivos.

O Reliability Diagram obtido para o Naive Bayes apresentou **ECE = 0.134**. Visualmente, a curva do modelo ficou maioritariamente abaixo da diagonal de calibração perfeita. Isto indica **overconfidence**: em média, o modelo atribui probabilidades superiores à accuracy observada. Esta interpretação segue diretamente os slides, onde é indicado que, num reliability diagram, pontos abaixo da diagonal correspondem a overconfidence, enquanto pontos acima indicam underconfidence.

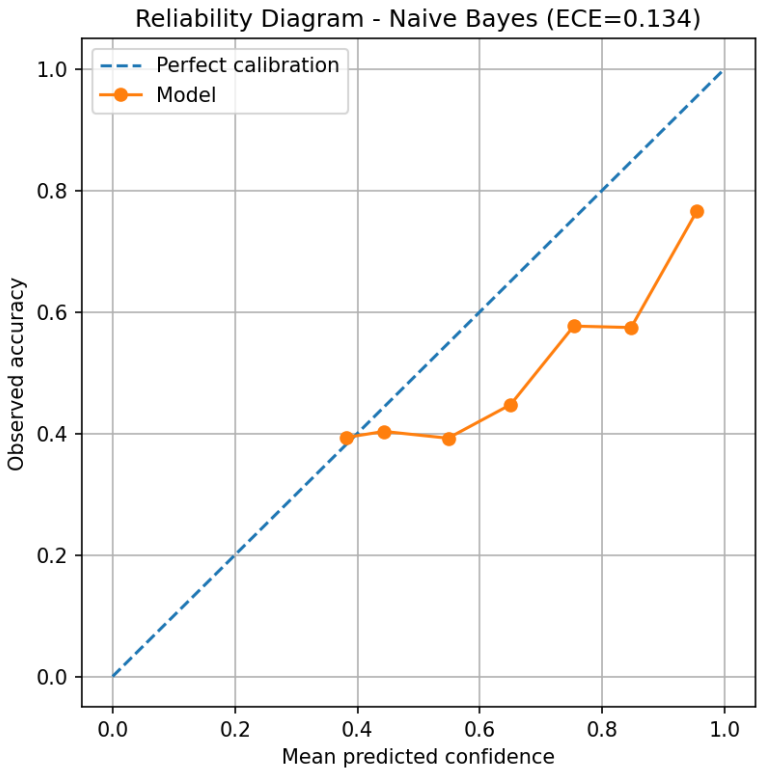


Figura 3 — Reliability Diagram do Naive Bayes. A curva abaixo da diagonal indica sobreconfiança do modelo.

Este resultado é consistente com o comportamento observado nas métricas. O modelo consegue obter uma accuracy razoável, mas o Log Loss permanece próximo do valor de uma previsão uniforme porque o modelo atribui, em alguns casos, probabilidades demasiado confiantes a previsões erradas. Esta má calibração torna-se especialmente importante na Parte 3, uma vez que decisões de aposta baseadas em valor esperado dependem diretamente da qualidade das probabilidades previstas.

Em termos críticos, este resultado mostra que as probabilidades do Naive Bayes não devem ser usadas de forma acrítica. Embora o modelo seja simples, interpretável e produza distribuições de probabilidade, a hipótese de independência condicional pode levar a probabilidades excessivamente confiantes. Uma possível melhoria futura seria aplicar calibração pós-processamento, como Platt Scaling, Isotonic Regression ou Temperature Scaling, métodos também referidos nos slides como formas de ajustar probabilidades após o treino.

4.4 Conformal Prediction

Para complementar a avaliação da incerteza, foi aplicada Conformal Prediction ao classificador Naive Bayes. A motivação desta técnica é transformar uma previsão pontual numa previsão em conjunto. Em vez de devolver apenas uma classe, como H, o modelo pode devolver um conjunto

de classes plausíveis, como {H, D} ou {A, D, H}. Isto é particularmente útil em cenários incertos, uma vez que o tamanho do conjunto reflete a incerteza da previsão.

Nos slides, Conformal Prediction é apresentada como uma framework para produzir conjuntos de previsão em classificação, ou intervalos em regressão, com garantia de cobertura. Em classificação multiclasse, o conjunto de previsão é um subconjunto das classes possíveis, e a garantia desejada é que a classe verdadeira pertença ao conjunto com probabilidade pelo menos $1 - \alpha$.

Foi usado Split Conformal Prediction, separando os dados em treino, calibração e teste. O modelo foi treinado no conjunto de treino e o conjunto de calibração foi usado para calcular os scores de não conformidade. Para classificação, os slides sugerem o score:

$$s(x, y) = 1 - \hat{P}(Y = y \mid x)$$

Quanto maior este score, menos conforme é a classe $y$para a instância x. Depois de calcular os scores no conjunto de calibração, é escolhido um limiar $\hat{q}$correspondente ao nível de cobertura desejado. Para uma nova instância, incluem-se no conjunto de previsão todas as classes cujo score seja inferior ou igual a esse limiar.

No trabalho, foi usado $\alpha = 0.1$, correspondente a uma cobertura desejada de aproximadamente 90%. No conjunto de teste, o método produziu conjuntos de previsão de diferentes tamanhos. Alguns jogos receberam conjuntos unitários, indicando maior confiança do modelo, enquanto outros receberam conjuntos com duas ou três classes, indicando maior incerteza.

A distribuição dos tamanhos dos conjuntos de previsão é particularmente informativa. Quando o conjunto tem tamanho 1, o modelo considera apenas uma classe suficientemente plausível. Quando o conjunto tem tamanho 2, há ambiguidade entre dois resultados. Quando o conjunto tem tamanho 3, o modelo não consegue excluir nenhum dos resultados possíveis. Esta interpretação está de acordo com os slides, onde é referido que instâncias fáceis tendem a produzir conjuntos pequenos e instâncias ambíguas tendem a produzir conjuntos maiores.

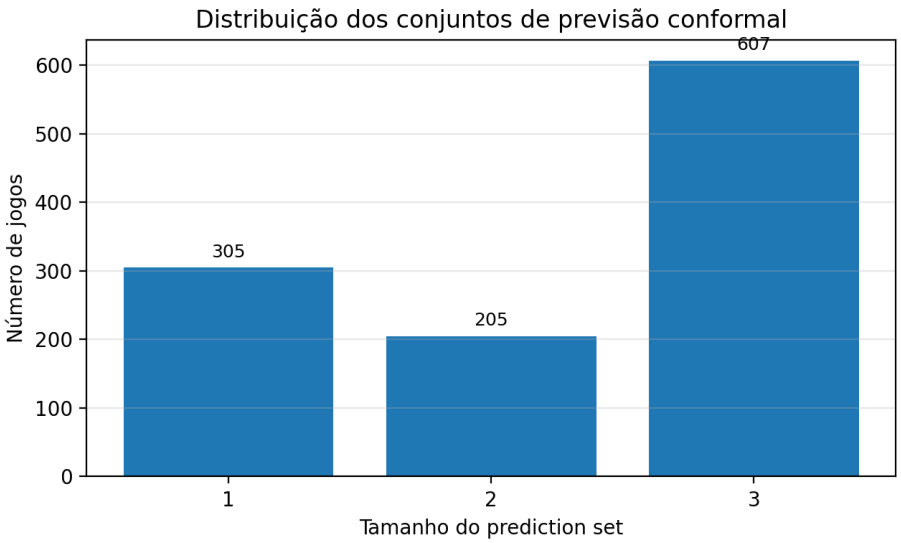


Figura 4 — Distribuição dos tamanhos dos conjuntos de previsão obtidos com Split Conformal Prediction.

A aplicação de Conformal Prediction mostrou-se útil porque fornece uma forma mais explícita de comunicar incerteza. Em futebol, onde o resultado é frequentemente incerto e pequenas diferenças de desempenho podem alterar o desfecho, a previsão em conjunto pode ser mais honesta do que uma previsão pontual. Em vez de afirmar apenas que o resultado previsto é H, o sistema pode indicar que tanto H como D são plausíveis, refletindo melhor a natureza incerta do problema.

4.5 Otimização Bayesiana dos hiperparâmetros

Por fim, foi aplicada Bayesian Optimization ao hiperparâmetro αdo Naive Bayes. O objetivo foi procurar uma configuração que melhorasse o desempenho probabilístico do modelo, usando Log Loss como critério de avaliação. A escolha de otimizar Log Loss é coerente com o foco do projeto: pretende-se melhorar a qualidade das probabilidades, não apenas a classe final prevista.

A Bayesian Optimization é adequada neste contexto porque permite explorar o espaço de hiperparâmetros de forma mais eficiente do que uma pesquisa exaustiva simples. Nos slides, esta técnica é apresentada como uma estratégia de otimização que usa um modelo substituto, frequentemente um Gaussian Process, para guiar a procura por configurações promissoras, equilibrando exploração e exploração. Também é referida como uma abordagem sample-efficient, especialmente útil quando cada avaliação é custosa.

No caso deste projeto, a otimização levou a uma melhoria de Log Loss, de 1.109 para 1.074, e de Brier Score, de 0.618 para 0.609. Embora esta melhoria seja limitada, ela mostra que o ajuste do parâmetro de suavização tem impacto nas probabilidades previstas. O facto de a accuracy se manter inalterada reforça novamente a diferença entre avaliar classes previstas e avaliar distribuições de probabilidade.

4.6 Síntese da Parte 2

De forma geral, a Parte 2 mostrou que o Naive Bayes é capaz de aprender algum sinal a partir das variáveis discretizadas, obtendo uma accuracy superior a uma previsão puramente uniforme e um Brier Score melhor do que a baseline uniforme. No entanto, os valores de Log Loss próximos de $\log(3)$e o Reliability Diagram com ECE = 0.134 indicam que as probabilidades do modelo ainda são limitadas e apresentam sobreconfiança.

A Conformal Prediction permitiu complementar esta análise ao transformar previsões pontuais em conjuntos de previsão, tornando a incerteza mais explícita. Já a Bayesian Optimization melhorou modestamente as métricas probabilísticas, sem alterar a accuracy. Estes resultados justificam a necessidade da Parte 3: se as probabilidades do modelo não estão bem calibradas, então decisões baseadas diretamente nelas, como apostas por valor esperado, podem produzir resultados financeiros negativos mesmo quando a accuracy parece aceitável.

5. Teoria de utilidade e tomada de decisão

A terceira parte do trabalho teve como objetivo transformar as probabilidades previstas pelos modelos em decisões concretas. Até este ponto, os modelos tinham sido avaliados sobretudo enquanto sistemas de previsão probabilística. No entanto, o enunciado do projeto pede também a avaliação da sua utilidade, comparando as probabilidades previstas com as odds do respetivo jogo. Esta distinção é importante porque um modelo pode ter uma performance preditiva razoável e, ainda assim, originar más decisões quando usado num contexto de aposta.

Esta ideia está diretamente relacionada com os slides de teoria de utilidade, onde é salientado que o desenvolvimento de modelos se foca muitas vezes em métricas como erro ou accuracy, mas que estas métricas nem sempre correspondem à utilidade real após a aplicação do modelo. Nos slides, é referido que probabilidades corretas não são suficientes: é necessário escolher a ação que maximiza a utilidade esperada.

5.1 Conversão das odds em probabilidades implícitas

Para comparar o modelo com o mercado, as odds foram convertidas em probabilidades implícitas. Para cada resultado $k \in \{H, D, A\}$, a probabilidade implícita bruta é dada por:

$$p_{raw}(k) = \frac{1}{odds(k)}$$

No entanto, a soma destas probabilidades é geralmente superior a 1 devido à margem da casa de apostas. Por isso, as probabilidades foram normalizadas:

$$p_{odds}(k) = \frac{1/odds(k)}{1/h_odds + 1/d_odds + 1/a_odds}$$

Desta forma, para cada jogo passou a existir uma distribuição de probabilidades baseada nas odds:

$$P_{odds}(H), P_{odds}(D), P_{odds}(A)$$

Esta distribuição foi usada como baseline de mercado. A comparação com as probabilidades do modelo permite identificar situações em que o modelo discorda das odds. Essas situações são particularmente relevantes porque, teoricamente, uma aposta só terá valor se o modelo estimar uma probabilidade superior à probabilidade implícita no mercado.

5.2 Valor esperado das apostas

A decisão de apostar foi formulada através do valor esperado. Para cada resultado possível, foi calculado:

$$EV(k) = P_{model}(k) \times odds(k) - 1$$

Se $EV(k) > 0$, então, segundo as probabilidades do modelo, essa aposta teria valor esperado positivo. A estratégia baseada no modelo escolheu, para cada jogo, o resultado com maior EV, apostando apenas quando esse valor era positivo.

Esta formulação segue o princípio de Maximum Expected Utility apresentado nos slides: para cada ação, calcula-se a utilidade esperada somando os possíveis estados ponderados pelas respetivas probabilidades, escolhendo depois a ação com maior utilidade esperada. No contexto deste trabalho, os estados correspondem aos resultados reais do jogo (H, D, A), as ações correspondem a apostar num desses resultados ou não apostar, e a utilidade corresponde ao lucro ou prejuízo obtido.

5.3 Estratégias avaliadas

Foram avaliadas quatro estratégias principais:

Estratégia	**Descrição**
Modelo com EV positivo	Apostar no resultado com maior valor esperado positivo segundo o modelo
Favorito pelas odds	Apostar sempre no resultado com menor odd
Reject Option	Apostar apenas quando a confiança do modelo é superior a um limiar
Deferência para odds	Usar o modelo quando está confiante e deferir para as odds quando está incerto

A estratégia "favorito pelas odds" foi usada como baseline simples de mercado. Esta estratégia seleciona sempre a menor odd entre h_odds, d_odds e a_odds, ou seja, o resultado considerado mais provável pelo mercado.

A estratégia com Reject Option foi introduzida para lidar com a incerteza do modelo. Nos slides de Reject Option, esta abordagem é definida como a possibilidade de um classificador devolver uma abstenção em vez de uma classe quando a confiança é baixa. A regra usada nos slides é rejeitar quando:

$$\max_k \hat{P}(Y = k \mid x) < \theta$$

onde θ é o limiar de confiança. No trabalho, esta ideia foi adaptada ao contexto de apostas: quando a confiança máxima do modelo era inferior ao limiar, a estratégia não apostava.

Por fim, foi testada uma estratégia de deferência para as odds. Em vez de simplesmente não apostar nos casos incertos, o sistema passa a usar a decisão baseada nas odds. Esta abordagem está relacionada com a ideia de *learning to defer*, discutida nos slides, onde decisões difíceis são encaminhadas para outro decisor ou sistema em vez de serem forçadas pelo modelo principal.

5.4 Resultados das estratégias

Os resultados obtidos foram os seguintes:

Estratégia	Nº jogos	Nº apostas	Hit rate	Lucro	ROI
Modelo com EV positivo	1117	1107	0.4571	-75.14	-0.0679
Favorito pelas odds	1117	1117	0.5936	+36.21	+0.0324
Reject Option, $\theta \approx 0.80$	1117	371	0.7062	-7.58	-0.0204
Deferência para odds, $\theta \approx 0.80$	1117	1114	0.5820	+17.87	+0.0160

A estratégia baseada apenas no modelo e no valor esperado gerou prejuízo, com lucro total de -75.14 unidades e ROI de -6.79%. Este resultado é particularmente relevante porque a estratégia apostou em 1107 dos 1117 jogos, ou seja, quase sempre encontrou uma aposta com valor esperado positivo. Isto indica que o modelo estava a identificar demasiadas oportunidades de valor, o que é coerente com a análise de calibração da Parte 2: o Reliability Diagram mostrou que o modelo estava sobreconfiante.

A baseline baseada no favorito das odds obteve o melhor resultado financeiro, com lucro de +36.21 unidades e ROI de +3.24%. Este resultado não deve ser interpretado como prova de que apostar sempre no favorito é uma estratégia lucrativa em geral, pois pode depender do período específico do conjunto de teste. No entanto, dentro deste trabalho, mostra que as odds foram uma baseline muito forte e que o mercado capturou informação relevante que o modelo não conseguiu explorar de forma suficientemente fiável.

A estratégia com Reject Option reduziu fortemente o número de apostas, de 1107 para 371, e aumentou o hit rate para 70.62%. Este comportamento é esperado: ao rejeitar previsões de menor confiança, o sistema passa a atuar apenas em casos onde o modelo está mais seguro. Os slides descrevem precisamente este trade-off: aumentar o limiar de rejeição reduz a cobertura, mas tende a aumentar a performance seletiva nas instâncias respondidas. No entanto, apesar do aumento do hit rate, o ROI continuou negativo. Isto mostra que acertar mais vezes não é suficiente para gerar lucro; é necessário acertar apostas cujo payoff compense o risco assumido.

A estratégia de deferência para as odds obteve ROI positivo, embora inferior ao da baseline de odds. Esta estratégia produziu lucro de +17.87 unidades e ROI de +1.60%. O resultado sugere que usar as odds como sistema alternativo nos casos em que o modelo está incerto é mais robusto do que usar apenas o modelo. No entanto, como ainda ficou abaixo da baseline das odds, não há evidência de que o modelo acrescente valor financeiro consistente face ao mercado.

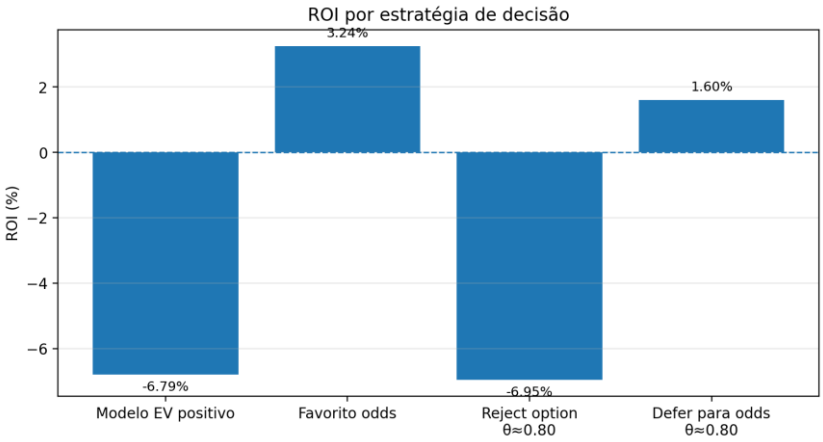


Figura 5 — ROI por estratégia de decisão no conjunto de teste.

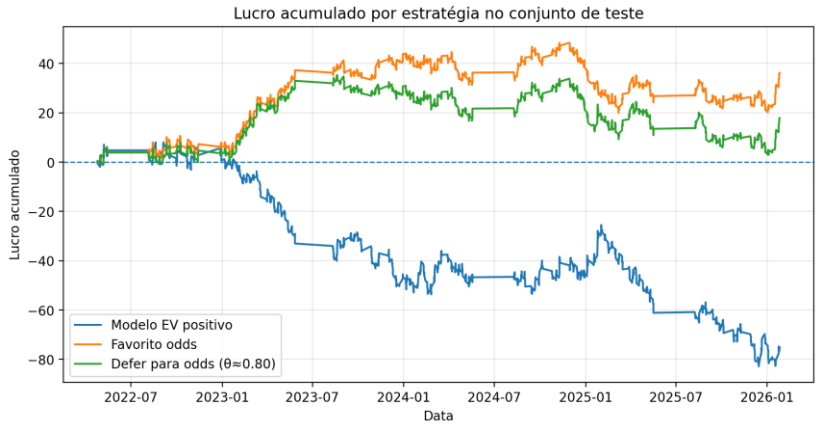


Figura 6 — Lucro acumulado ao longo do tempo para as principais estratégias de decisão.

5.5 Efeito do limiar de rejeição

Foi também analisado o impacto do limiar θ da Reject Option. À medida que θ aumenta, o modelo exige maior confiança para apostar. Consequentemente, a cobertura diminui: o número de apostas realizadas baixa progressivamente. Este comportamento foi observado no gráfico "Coverage vs Reject Threshold", onde a taxa de apostas desce de valores próximos de 1 para cerca de 0.33 quando θ se aproxima de 0.80.

O gráfico "ROI vs Reject Threshold" mostrou que o ROI melhora à medida que o limiar aumenta, aproximando-se de zero, mas sem se tornar positivo para a estratégia de rejeição pura. Isto reforça uma conclusão importante: a Reject Option é útil para reduzir decisões arriscadas e limitar perdas, mas não resolve sozinha o problema da má calibração das probabilidades do modelo.

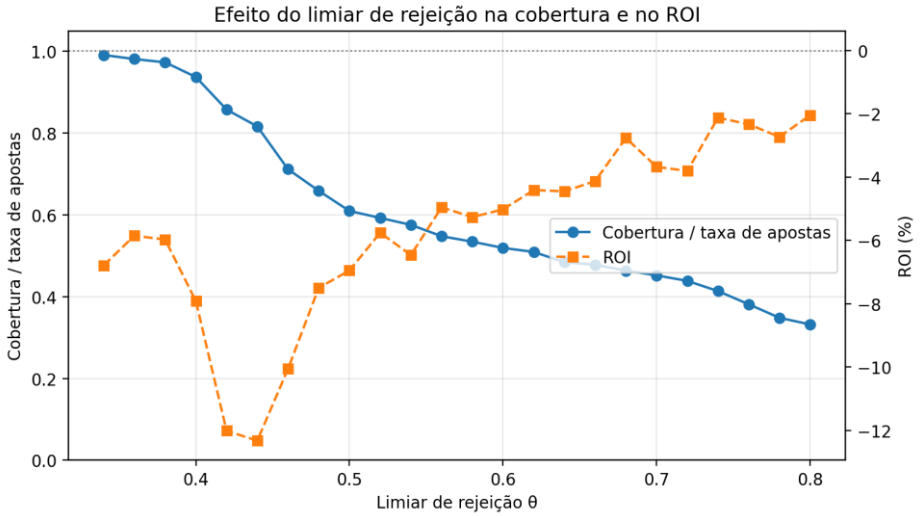


Figura 7 — Efeito do limiar de rejeição na cobertura e no ROI da estratégia com Reject Option.

Este resultado está de acordo com a teoria apresentada nos slides. A Reject Option formaliza um compromisso entre cobertura e performance seletiva: rejeitar mais pode melhorar a qualidade das previsões aceites, mas reduz o número de casos em que o sistema toma uma decisão. No caso deste projeto, esse compromisso foi visível, mas a melhoria de seletividade não foi suficiente para superar a baseline das odds.

5.6 Análise crítica da utilidade

A Parte 3 mostra que a transição de previsão probabilística para decisão é crítica. O modelo Naive Bayes apresentou alguma capacidade preditiva, mas as suas probabilidades não estavam suficientemente calibradas para serem usadas diretamente numa estratégia de apostas baseada em valor esperado. Como o cálculo de EV depende diretamente de $P_{model}(k)$, qualquer sobreconfiança do modelo transforma-se em falsas oportunidades de aposta.

Isto demonstra uma diferença fundamental entre avaliação preditiva e avaliação de utilidade. Um modelo pode ter accuracy razoável e ainda assim produzir prejuízo financeiro, porque a decisão depende não apenas da classe mais provável, mas da relação entre probabilidade prevista, odd e payoff. Esta conclusão está em linha com os slides de utilidade, onde é referido que métricas de performance offline podem não ser uma boa aproximação da utilidade final do sistema.

Outro ponto importante é que as odds representam uma fonte de informação muito forte. Ao contrário do modelo, que usa apenas variáveis disponíveis no dataset, o mercado de apostas pode refletir informação adicional, como lesões, notícias recentes, qualidade das equipas, contexto competitivo, volume de apostas e expectativas públicas. Assim, não é surpreendente que a baseline das odds tenha superado o modelo.

No entanto, o resultado negativo do modelo não significa que a abordagem seja inútil. Pelo contrário, a análise permitiu identificar limitações claras: má calibração, sobreconfiança e dificuldade em transformar probabilidades em decisões lucrativas. A Reject Option e a estratégia de deferência mostraram formas de usar a incerteza para controlar o risco, mesmo que não tenham sido suficientes para superar o mercado. Isto está alinhado com os slides de quantificação de incerteza, onde a incerteza é apresentada como essencial para tomada de decisão sensível ao risco, fiabilidade e reject option.

6. Discussão crítica

Os resultados obtidos mostram que a previsão de resultados de futebol é um problema difícil e altamente incerto. Embora os modelos tenham aprendido algum sinal a partir dos dados, a qualidade das probabilidades previstas revelou limitações importantes. Isto é coerente com o domínio: o resultado de um jogo depende não só de fatores históricos, como forma recente e desempenho ofensivo, mas também de fatores não incluídos no dataset, como lesões, contexto competitivo, rotação de jogadores, motivação e eventos aleatórios durante a partida.

Uma limitação relevante está nas variáveis utilizadas. O dataset contém resultados históricos e odds, mas não inclui informação contextual detalhada, como classificação das equipas, importância do jogo, ausências, mudanças de treinador ou estatísticas avançadas. Além disso, várias variáveis foram discretizadas para permitir a construção de Redes Bayesianas e a estimação de tabelas de probabilidade condicionais. Esta discretização torna o modelo mais interpretável, mas também implica perda de informação, pois equipas com valores numéricos diferentes podem acabar na mesma categoria.

Na Parte 1, as Redes Bayesianas foram úteis pela sua interpretabilidade. A estrutura manual permitiu representar hipóteses simples do domínio, enquanto a estrutura aprendida automaticamente permitiu comparar essas hipóteses com dependências encontradas nos

dados. No entanto, a estrutura manual depende das escolhas do investigador, e a estrutura aprendida automaticamente não deve ser interpretada como causal, mas apenas como uma estrutura que melhora um critério estatístico.

Na Parte 2, o Naive Bayes obteve resultados moderados. A accuracy foi razoável para um problema de três classes, mas o Log Loss ficou próximo de log(3), valor associado a uma previsão uniforme. O Brier Score foi melhor do que a baseline uniforme, indicando algum sinal útil, mas o Reliability Diagram mostrou que o modelo estava sobreconfiante, com ECE = 0.134. Esta má calibração é especialmente importante porque as probabilidades foram depois usadas para decisões baseadas em valor esperado.

Na Parte 3, verificou-se que o modelo não superou as odds em termos de utilidade financeira. A estratégia baseada em EV positivo gerou prejuízo, apesar de o modelo identificar muitas apostas como tendo valor esperado positivo. Este resultado mostra que uma má calibração pode transformar-se diretamente em más decisões. A Reject Option reduziu o número de apostas e aumentou o hit rate, mas não tornou o ROI positivo. A estratégia de deferência para as odds foi mais robusta do que usar apenas o modelo, embora ainda tenha ficado abaixo da baseline baseada no favorito das odds.

Assim, a principal conclusão crítica é que o modelo probabilístico foi útil para representar incerteza, analisar probabilidades e identificar limitações, mas não foi suficientemente fiável para substituir as odds enquanto estratégia de decisão. Isto não invalida o projeto; pelo contrário, mostra a importância de avaliar probabilidades, calibração e utilidade de forma conjunta. Em problemas incertos, prever a classe mais provável não é suficiente: é necessário avaliar se as probabilidades produzidas são confiáveis e se conduzem a boas decisões.

7. Conclusão

Este projeto aplicou métodos de Inteligência Artificial Probabilística à previsão de resultados de jogos da liga portuguesa de futebol e à análise da sua utilidade num contexto de odds desportivas. O trabalho foi organizado em três componentes principais: Redes Bayesianas, classificação probabilística com quantificação de incerteza e tomada de decisão baseada em teoria de utilidade.

Na primeira parte, foram construídas Redes Bayesianas com variáveis discretizadas relacionadas com forma recente, ataque, confrontos diretos e odds. A estrutura manual permitiu representar conhecimento do domínio de forma interpretável, enquanto a estrutura aprendida automaticamente forneceu uma comparação baseada nos dados. A análise por D-separação, a estimação de parâmetros por MLE e estimação Bayesiana, e as queries probabilísticas

mostraram que a rede pode responder a cenários relevantes, ainda que dependa fortemente da estrutura escolhida e da discretização das variáveis.

Na segunda parte, foi treinado um classificador Naive Bayes para prever H, D e A. O modelo obteve uma accuracy razoável, mas as métricas probabilísticas revelaram limitações. A otimização Bayesiana melhorou ligeiramente o Log Loss e o Brier Score, sem alterar a accuracy, mostrando que a qualidade das probabilidades pode mudar mesmo quando a classe prevista permanece igual. O Reliability Diagram indicou sobreconfiança, e a Conformal Prediction permitiu expressar a incerteza através de conjuntos de previsão.

Na terceira parte, as probabilidades previstas foram usadas para tomar decisões de aposta. A estratégia baseada no valor esperado do modelo gerou prejuízo, mostrando que probabilidades mal calibradas podem conduzir a decisões desfavoráveis. A baseline baseada no favorito das odds teve melhor desempenho, confirmando que o mercado é uma referência forte. A Reject Option reduziu a cobertura e aumentou o hit rate, mas não tornou o ROI positivo. A deferência para as odds foi mais robusta do que usar apenas o modelo, embora não tenha superado a baseline das odds.

Conclui-se que, neste dataset e com estes modelos, o sistema probabilístico não superou o mercado de odds em termos de utilidade financeira. No entanto, o projeto cumpriu o objetivo de aplicar técnicas probabilísticas para modelar incerteza, avaliar calibração e estudar a relação entre previsão e decisão. Como trabalho futuro, seria relevante explorar modelos mais expressivos, incorporar variáveis contextuais adicionais e aplicar métodos de calibração pós-processamento antes de usar as probabilidades em estratégias de decisão.